Weekly Report 2

EDA and Data Exploration

Kelompok 4
Fransiska Nadine Clarissa
Ahsan Faqih

Dataset

Overview Data Asli

Baris	Kolom
7728394	46

Berdasarkan distribusi severity per tahun, 2020 dan 2022 memiliki proporsi kelas yang lebih representatif dibanding tahun-tahun yang lain

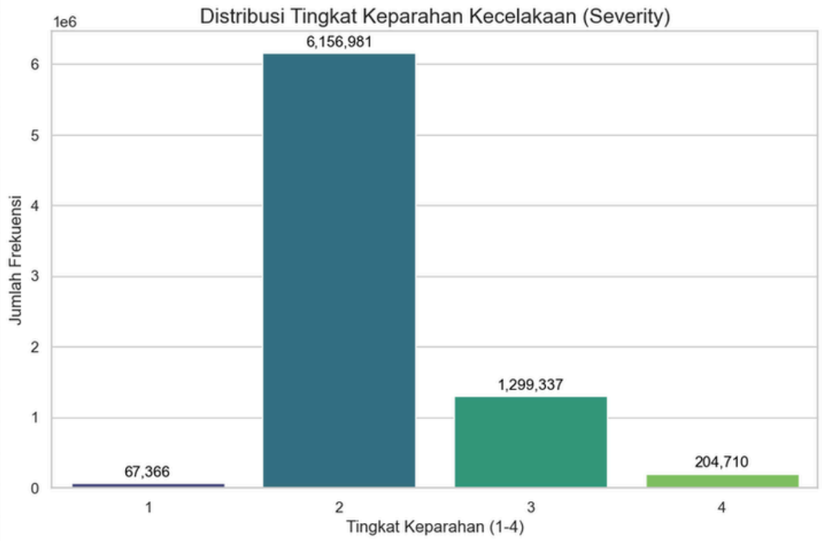

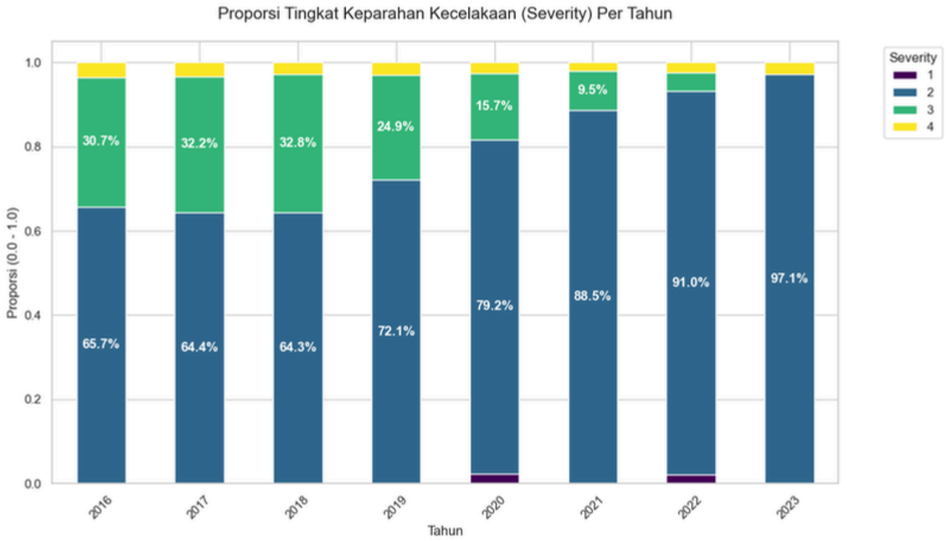

Dataset

Overview Data Asli

	1	2	3	4
2020	28371	934123	185352	31067
2022	37875	1603346	77957	43274

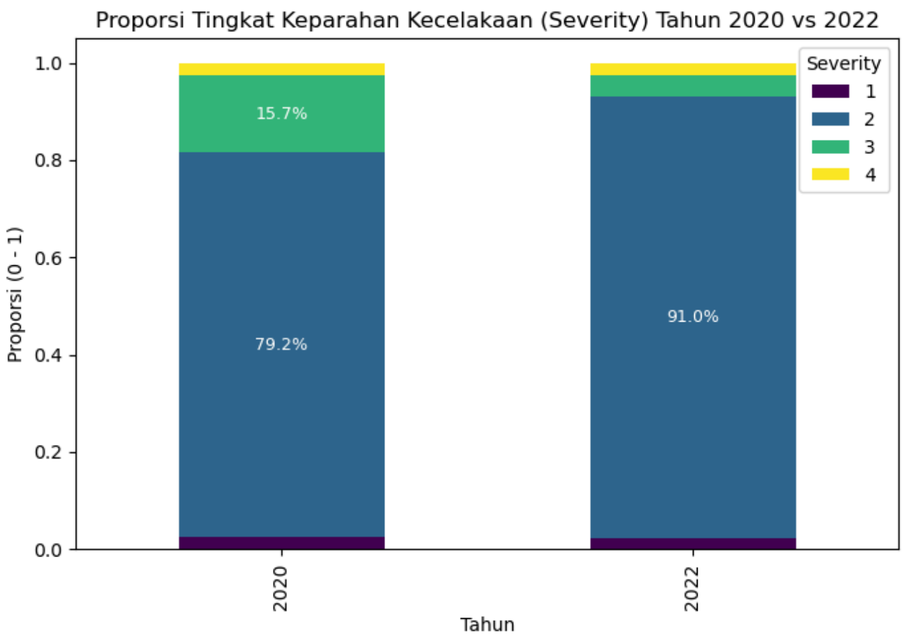

Rasio Perbandingan

	Ratio	Total Data
2020	32.925276	1178913
2022	42.332568	1762452

Berdasarkan rasio yang ada, kami memilih dataset tahun 2020 untuk dianalisis dengan alasan:

- Distribusi severity pada tahun 2020 lebih seimbang dibandingkan tahun 2022 yang sangat didominasi oleh Severity 2.
- Data tahun 2020 memiliki jumlah data yang besar dengan proporsi kelas yang masih representatif untuk dianalisis.

EDA - 1

Ukuran Dataset

Baris	Kolom
1178913	47

Distribusi Severity

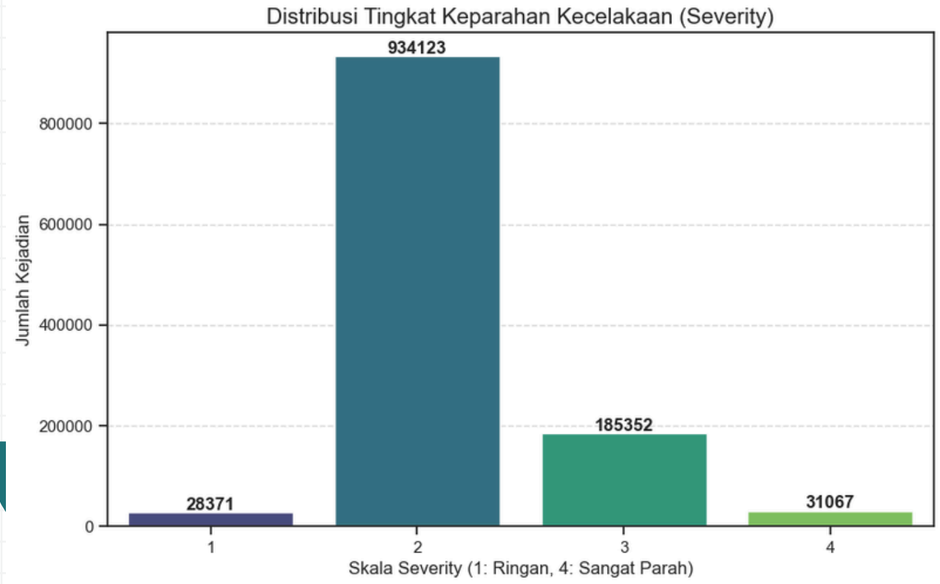

Jumlah Nilai Unik

State	49
Weather_Condition	93
Wind_Direction	18

Turning_Loop	1
Country	1

Missing Value

End_Lat	470244
End_Lng	470244

Sunrise_Sunset	377
Civil_Twilight	377
Nautical_Twilight	377
Astronomical_ Twilight	377

EDA - 1

Penjelasan Kolom

4 kolom terakhir digunakan untuk menjawab "Seberapa terang situasi saat terjadi kecelakaan?"

Sunrise Sunset	Waktu saat matahari tepat muncul atau hilang di cakrawala
Civil Twilight	Matahari baru saja tenggelam (0°-6° di bawah horison)
Nautical Twilight	Matahari sudah lebih jauh (6°-12° di bawah horison)
Astronomical Twilight	Matahari sudah sangat jauh (12°-18° di bawah horison)

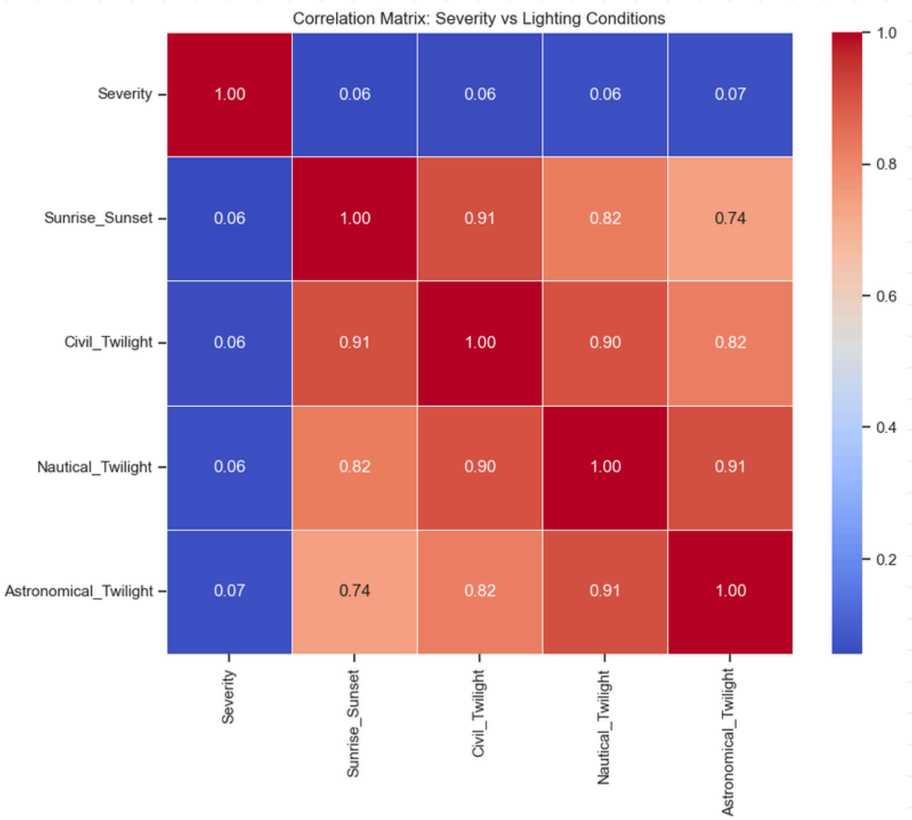

Variabel twilight memiliki korelasi yang sangat tinggi satu sama lain, yang menunjukkan bahwa variabel tersebut membawa informasi yang serupa.

EDA - 1

Persebaran Data Kolom Numerical

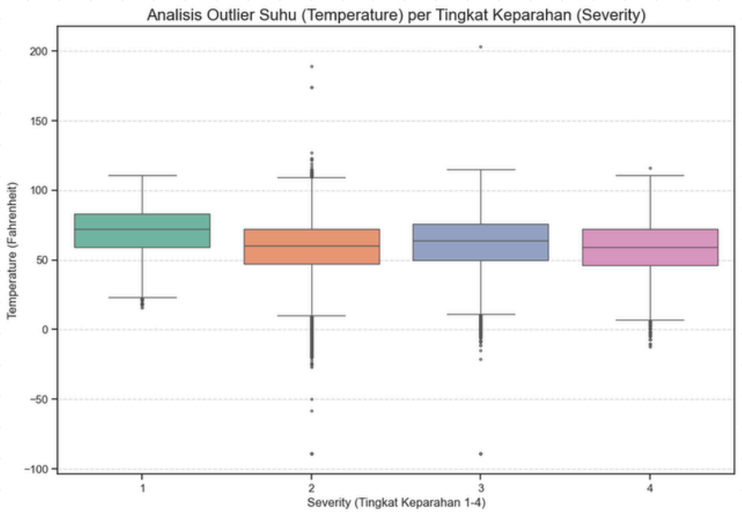

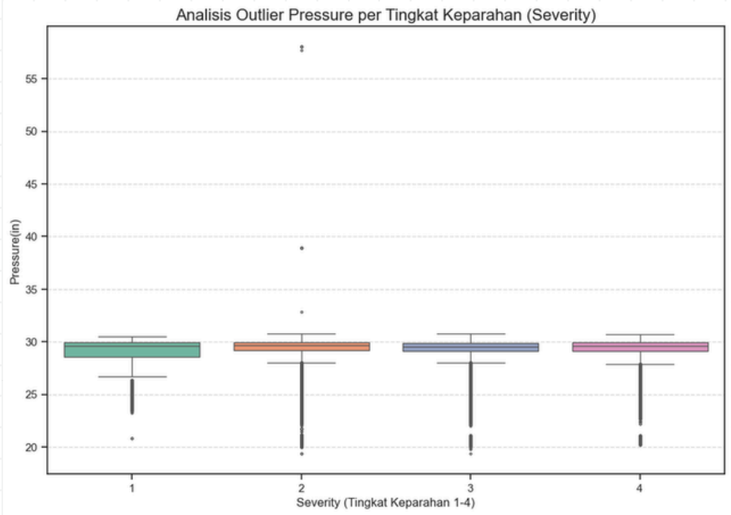

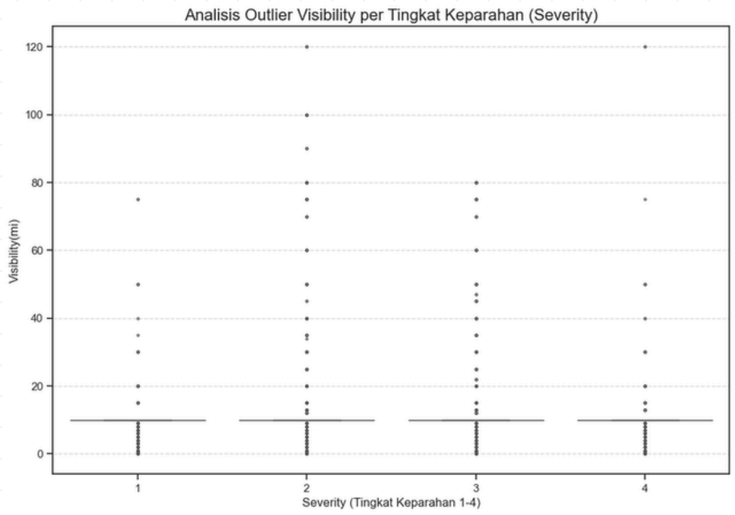

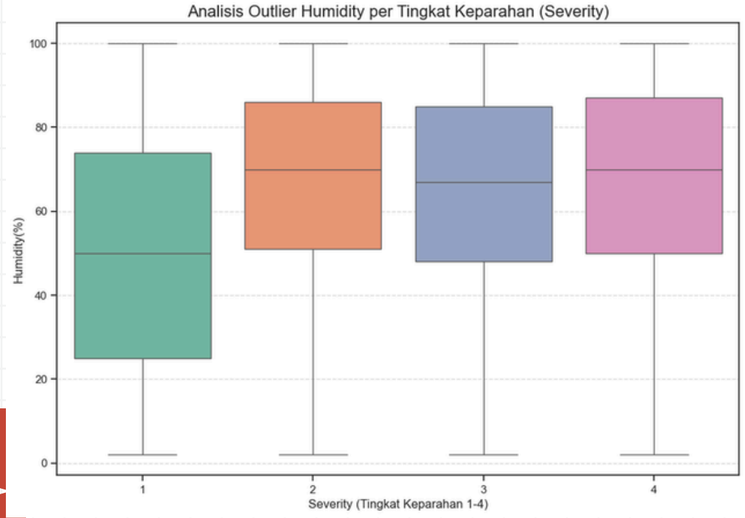

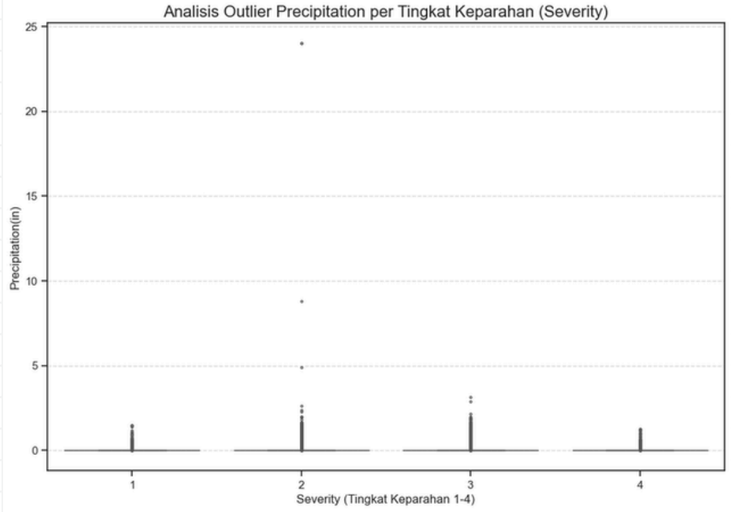

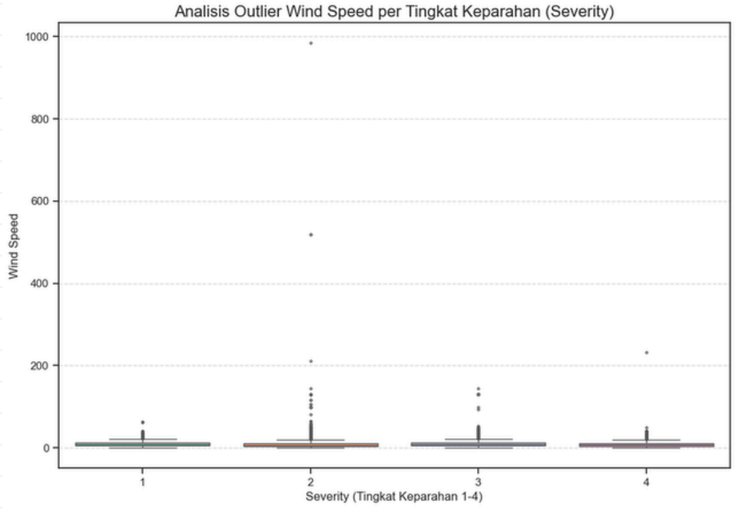

EDA - 1

Data Cuaca US di Tahun 2020

Source: Visual Crossing - NOAA (NCEI)

	Temperature (F)	Humidity (%)	Pressure (in)	Visibility (mil)	Precipitation (in)	Wind Speed (mph)
Max	98.7	95.6	30.6876	10	2.7	33.8
Min	21.3	32.3	29.3706	4	0.0	5.7

Menstandarisasi data anomali akibat kesalahan input (human error) ke dalam angka yang sesuai dengan kondisi US di tahun 2020

Nilai Korelasi Pearson

Start_Lat dan End_Lat : 0.999999
Start_Lng dan End_Lng : 0.999995
Wind_Chill dan Temperature : 0.9931

Hasil EDA - Pre Processing

- Kolom yang akan di drop: ID, Source, End_Lat, End_Lng, Description, Street, Weather_Timestamp, Zipcode, Sunrise_Sunset, Civil_Twilight, Nautical_Twilight, Turning_Loop, Country, Wind_Chill, Start_Lat, Start_Lng
- Mengubah tipe data Start_Time dan End_Time menjadi datetype
- Membuat kolom Duration untuk selisih Start_Time and End_Time
- Memperbaiki outlier di kolom numerikal
- Melakukan simplifikasi pada kolom Weather_Condition dan Wind_Direction
- Impute Weather_Condition based on Temperature, Precipitation, Visibility
- Impute kolom numerical dengan groupby Weather Condition menggunakan median
- Membuat geoplot berdasarkan state
- Membuat kolom Bulan dan Jam
- Membuat kolom road_features untuk menghitung fitur POI

After Pre Processing

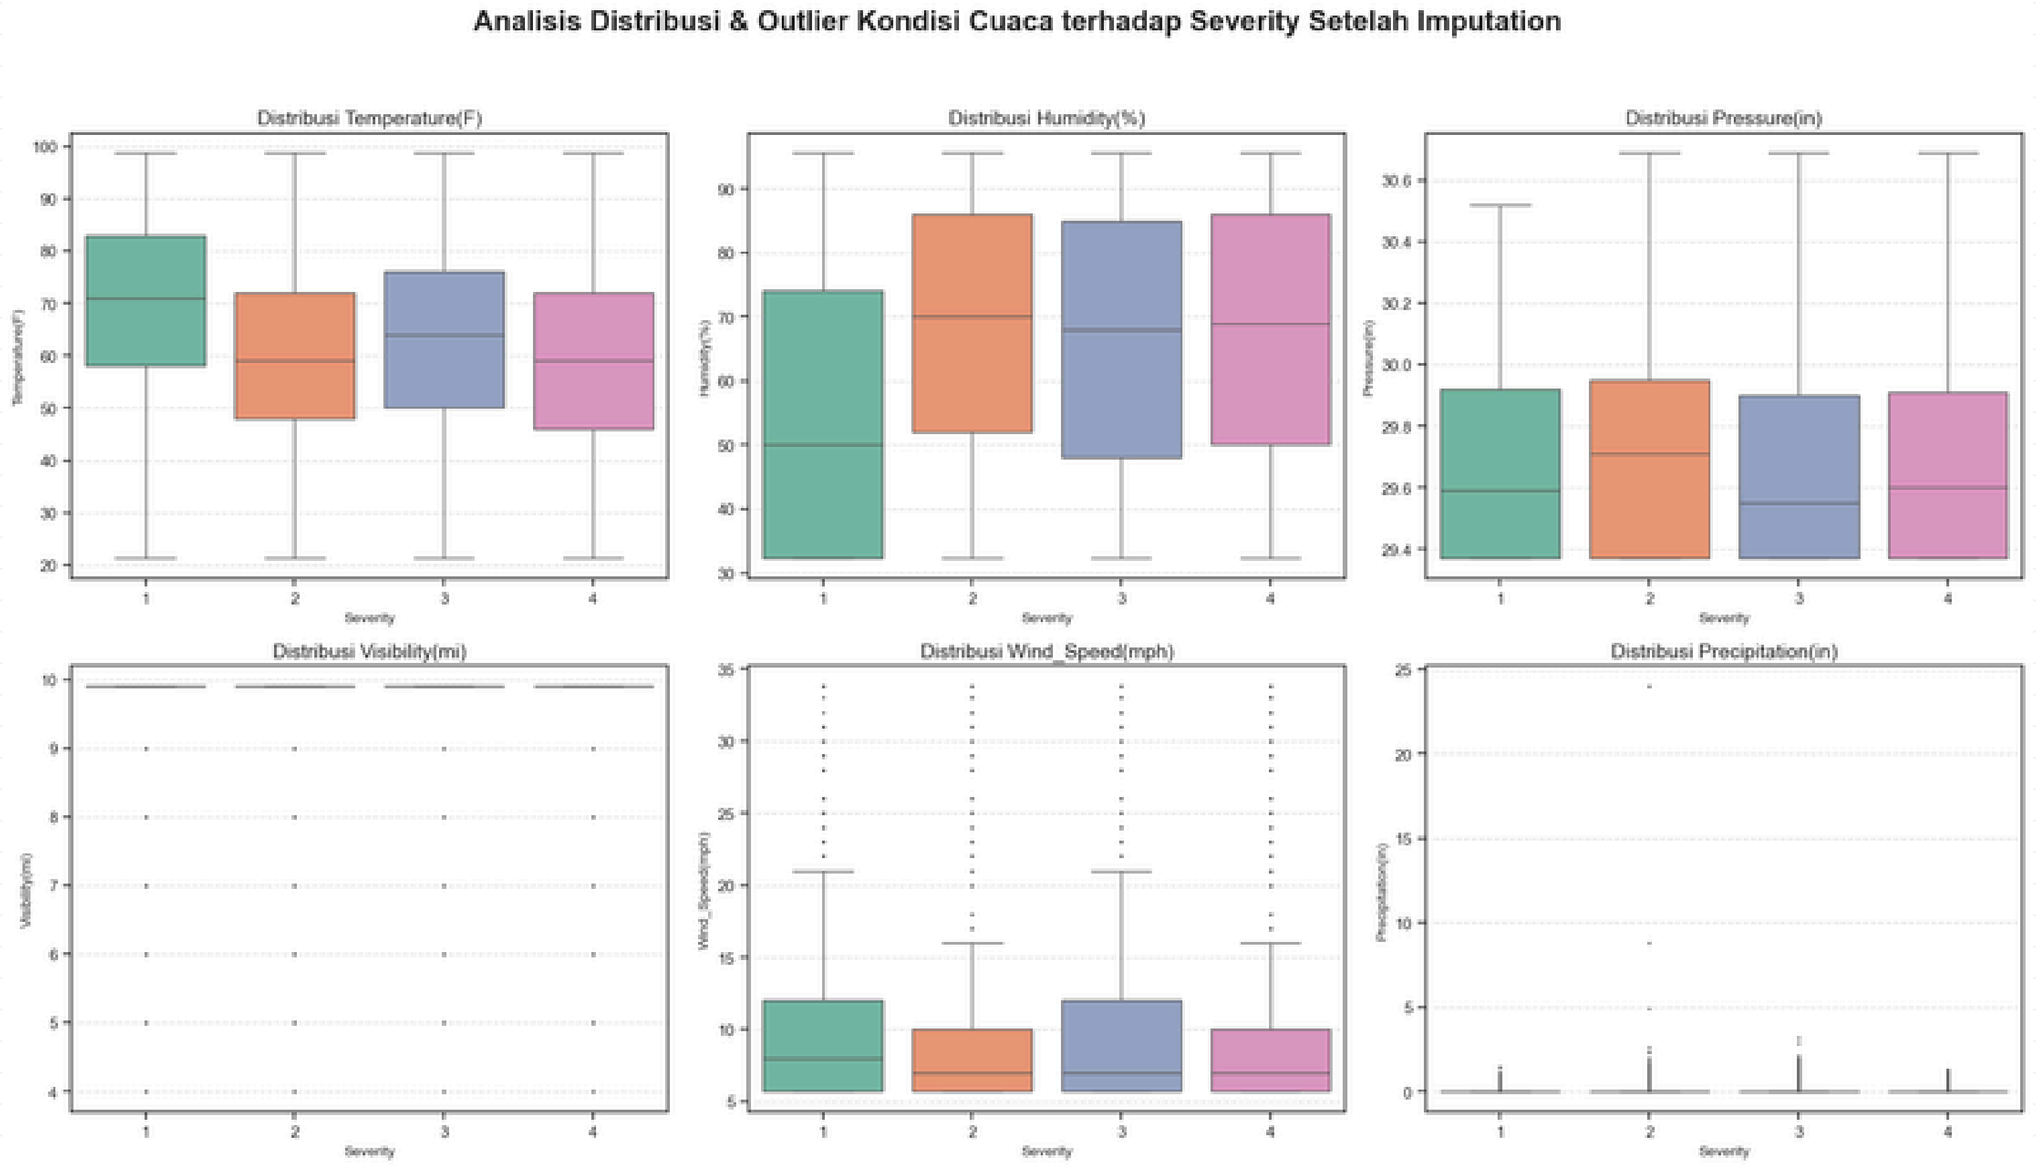

After Pre Processing

	Sebelum	Sesudah
Weather_Condition	93	7
Wind_Direction	18	10

	Sebelum	Sesudah
Jumlah Kolom	46	33
Missing Value	banyak	0

- Data numerical sudah sesuai dengan kondisi yang seharusnya
- Kolom yang redundant telah dibuang

EDA - 2

Nilai Korelasi Pearson dengan Severity

Distance(mi)	0.100393
Wind_Speed(mph)	0.038281
Junction	0.031613
Precipitation(in)	0.028347
Humidity(%)	0.012307

Traffic_Signal	-0.117975
Road_Features	-0.116210
Crossing	-0.111245
Pressure(in)	-0.044367
Stop	-0.036607

Distribusi Jumlah Berdasarkan Jam Kecelakaan

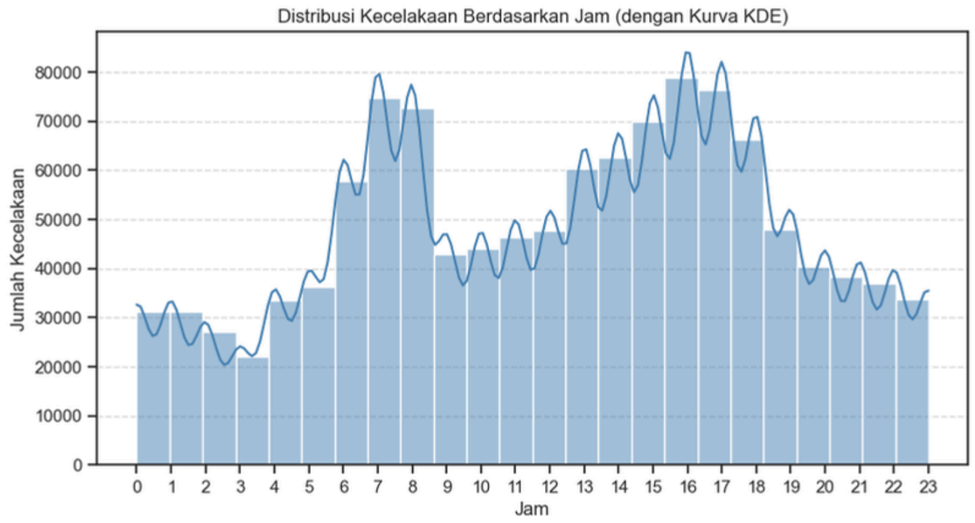

Puncak Kecelakaan di jam 07.00 - 08.00 dan jam 15.00 - 18.00

EDA - 2

Distribusi Jumlah Kecelakaan Tiap Bulan

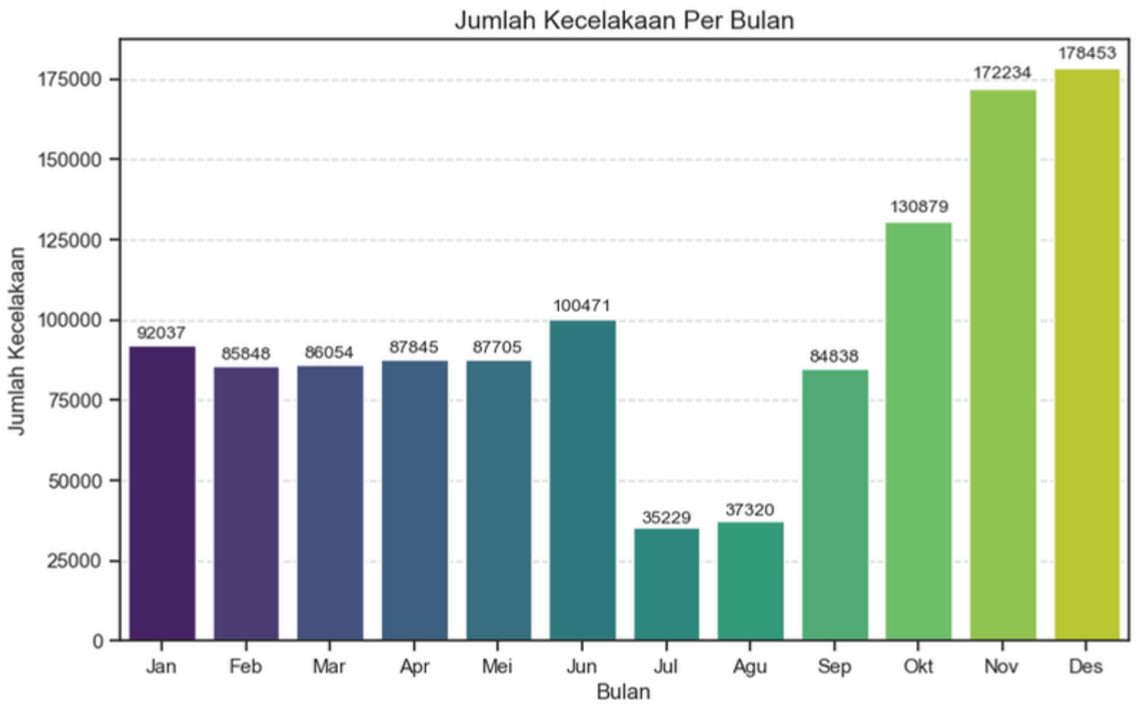

- Puncak Kecelakaan ada di bulan Oktober - Desember
- Oktober - Desember adalah transisi dari musim gugur ke musim dingin (Winter).

Distribusi Jumlah Kecelakaan Berdasarkan State

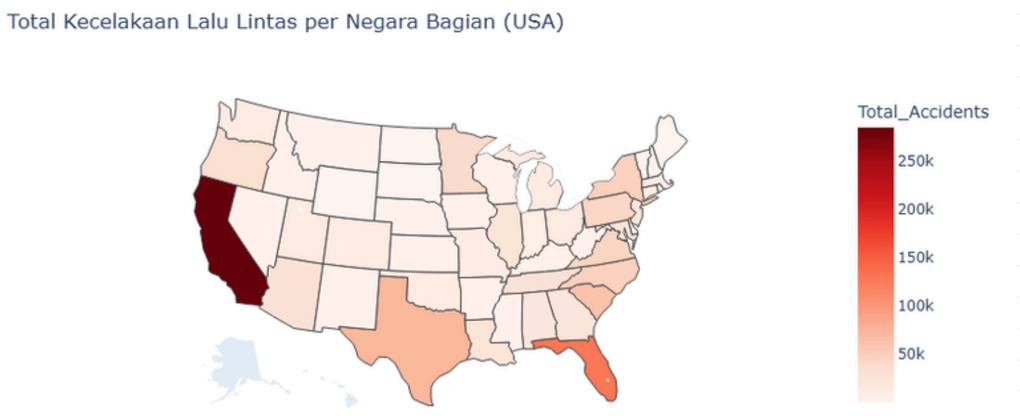

CA - California	285532
FL - Florida	130362
TX - Texas	73488

SC - South Carolina	62789
NY - New York	48805
NC - North Carolina	48633

EDA - 2

Rata-rata Severity Kecelakaan per State

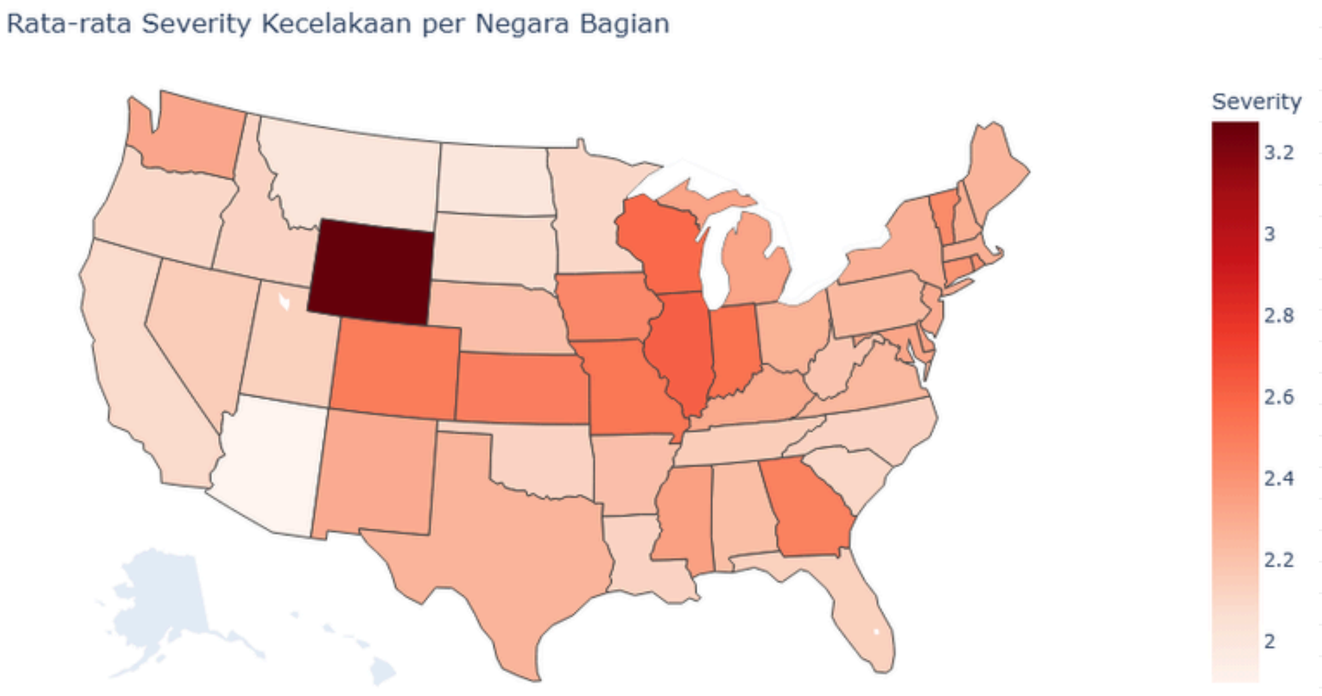

State	Mean	Count
WY - Wyoming	3.275862	29
IL - Illinois	2.611909	25007
WI - Wisconsin	2.575896	3933
IN - Indiana	2.545478	7806
MO - Missouri	2.528153	10372

Kecelakaan dengan Severity tinggi terpusat di tengah negara

EDA - 2

Rata-rata Severity Berdasarkan Road Feature

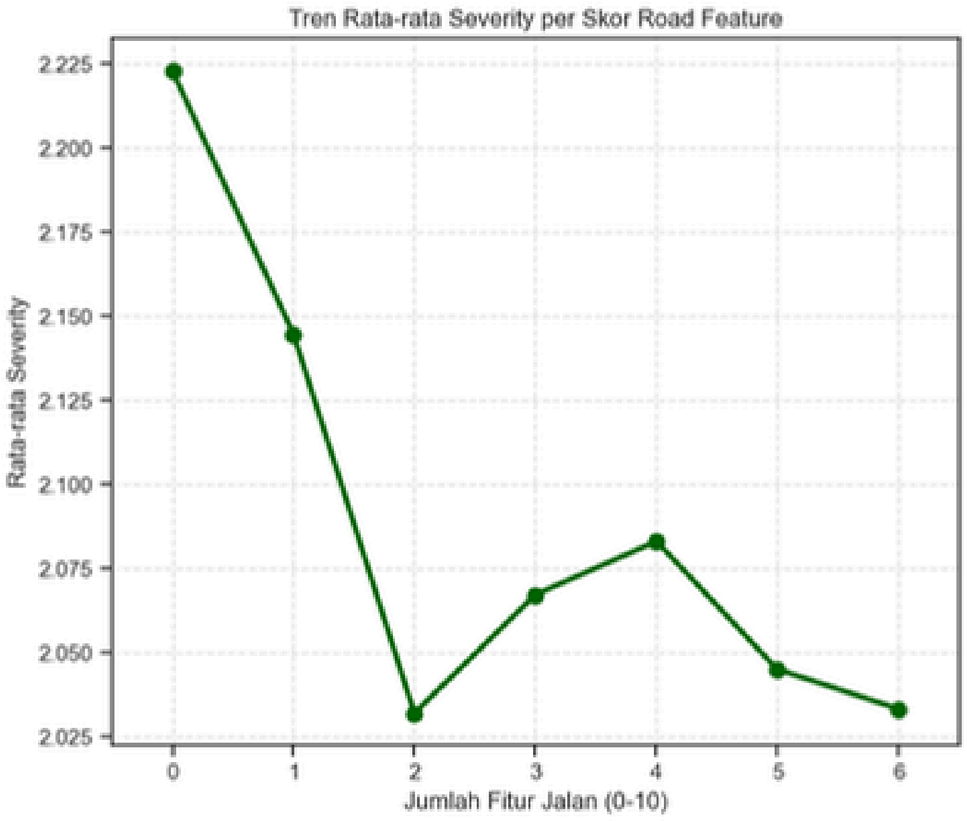

Jumlah Kecelakaan Berdasarkan Road Feature

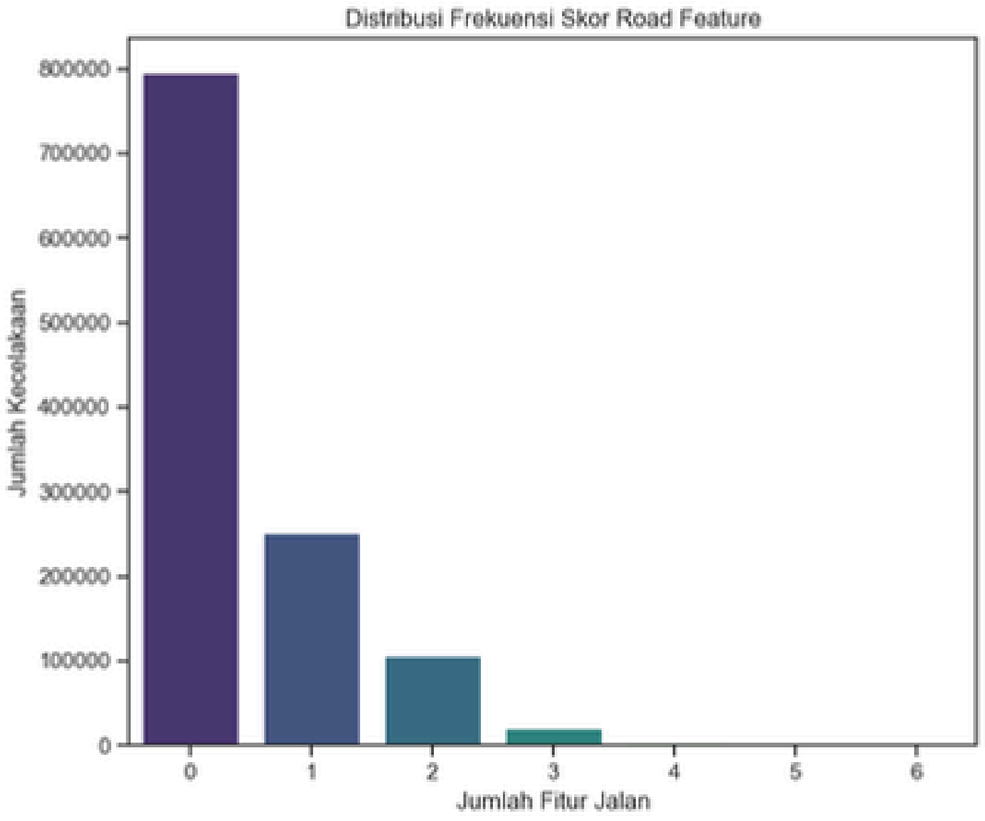

Hasil Akhir

- Data numerical sudah sesuai dengan kondisi yang seharusnya
- Kolom-kolom yang tidak relevan telah dibuang
- Kolom kategorikal yang memiliki banyak nilai unik telah disederhanakan
- Kolom yang redundant telah dibuang

Insight

- Puncak kecelakaan tertinggi ada di bulan Oktober - Desember (transisi musim gugur ke musim salju). Pada masa transisi, jarak pandang kemungkinan menjadi lebih rendah (salju/kabut) dan jalanan licin.
- California menjadi negara bagian dengan angka kecelakaan tertinggi
- Wyoming menjadi negara bagian dengan rata-rata severity tertinggi dengan jumlah kecelakaan yang sangat kecil
- Keberadaan Road Feature dapat menekan Severity suatu kecelakaan
- Daerah jalanan yang tidak memiliki Road Feature berpotensi menimbulkan kecelakaan yang tinggi

Terima Kasih