Weekly Report 3

Machine Learning Implementation

Presentation by **Group 4**

Maret 28, 2026

Weekly Report 2

Perubahan Metode Impute

- Kolom numerikal Cuaca di-impute berdasarkan median dari kolom City/State dan Month
- Kolom Weather Condition di-impute berdasarkan modus dari kolom City/State dan Month
- Data Cuaca diperbarui karena data kemarin belum mencakup 1 wilayah US sehingga nilai untuk melakukan capping ikut berubah
- Didapatkan 3 data kecelakaan terparah di US sebagai acuan untuk melakukan *capping* pada kolom Distance dan Durasi
- Mempertimbangkan nilai persentil 99% dan 99.9% untuk melakukan *capping*

Feature Engineering

- Membuat kolom Is_Weekend dan Is_Precipitating
- Melakukan binning pada kolom Hour → Late Night, Morning Rush, Office Hours, Evening Rush, Night
- Melakukan binning pada kolom Temperature → Freezing (<32°F), Cold (32-50°F), Moderate (50-80°F), Hot (>123°F)
- Melakukan binning pada kolom Distance → Local, Short Distance, Long Distance, Extreme (>300 mil)
- Melakukan binning pada kolom Duration → Short (<12h), Medium (12-24h), Long (24-36h), Extreme (>36h)
- Menghapus kolom Start Time dan End Time
- Menyesuaikan tipe data pada setiap kolom agar lebih sesuai

Feature Engineering - Unused

- Log Transformation: Distance, Wind Speed, Precipitation, Duration.
- Standard Scaling: Temperature.
- Robust Scaling: Distance, Duration, Wind Speed, Precipitation, Pressure.
- MinMax Scaling: Humidity, Visibility.

Namun...

- Model berbasis Tree bersifat robust terhadap skala data dan tidak mensyaratkan asumsi distribusi normal.
- Pengujian pada Random Forest dan LightGBM menunjukkan bahwa penggunaan Log Transform dan Scaling tidak memberikan peningkatan akurasi yang signifikan dibandingkan data mentah.
- Untuk efisiensi komputasi, model Tree dalam pipeline ini akan diimplementasikan tanpa tahap Log Transform maupun Scaling.

	Random Forest	**LightGBM**
Dengan Scaling	83.61%	72.26%
Tanpa Scaling	83.25%	72.15%

Feature Selection - Split - Encoding

Mutual Information **Spearman** **Cramer's V** **Feature Importance dari 3 Model**

Membuang 7 kolom

Roundabout, Bump, Traffic_Calming, No Exit, Railway, Give_Way, Amenity

Stratified Split (80:20) **Target Encoding :** **City, County, State**

---

	precision	recall	f1-score
1	0.11	0.77	0.20
2	0.93	0.54	0.60
3	0.37	0.58	0.45
4	0.11	0.53	0.18

Model
Logistic Regression

*dilakukan pada data scaling

Akurasi: 55.05%

Berdasarkan hasil akurasi yang diperoleh, model Tree ditetapkan sebagai model utama untuk tahap selanjutnya

Model
CatBoost

	precision	recall	f1-score
1	0.32	0.93	0.47
2	0.97	0.71	0.82
3	0.48	0.71	0.57
4	0.17	0.76	0.28

Akurasi: 71.51%

Model
Random Forest

	precision	recall	f1-score
1	0.53	0.81	0.64
2	0.94	0.86	0.90
3	0.56	0.73	0.63
4	**0.42**	**0.55**	**0.48**

Akurasi: 83.25%

Model
LightGBM

	precision	recall	f1-score
1	0.34	0.93	0.49
2	0.97	0.72	0.82
3	0.49	0.71	0.58
4	**0.17**	**0.76**	**0.28**

Akurasi: 72.11%

Model
XGBoost

	precision	recall	f1-score
1	0.73	0.65	0.69
2	0.89	0.95	0.92
3	0.69	0.53	0.60
4	**0.64**	**0.29**	**0.40**

Akurasi: 86.33%

Model Ensemble
LightGBM dan XGBoost

	precision	recall	f1-score
1	0.54	0.87	0.67
2	0.93	0.89	0.91
3	0.61	0.66	0.63
4	**0.37**	**0.53**	**0.43**

Akurasi: 84.26%

Kesimpulan Sementara

Model Random Forest

Lebih baik dalam memprediksi
Severity 4 dan Severity 3

Kita lebih mengutamakan

Recall → Menghindari False Negative

Hyperparameter Tuning

Random Search

Model
Ensemble

	precision	recall	f1-score
1	0.57	0.86	0.68
2	0.93	0.89	0.91
3	0.60	0.64	0.62
4	0.39	0.51	0.44

Akurasi: 84.26%

F1-Score Meningkat 0.43 → 0.44

Model
Random Forest

	precision	recall	f1-score
1	0.55	0.82	0.66
2	0.94	0.87	0.90
3	0.57	0.73	0.64
4	0.45	0.59	**0.51**

Akurasi: 83.83%

F1-Score Meningkat 0.48 → 0.51

Feature Importance

Model
Ensemble

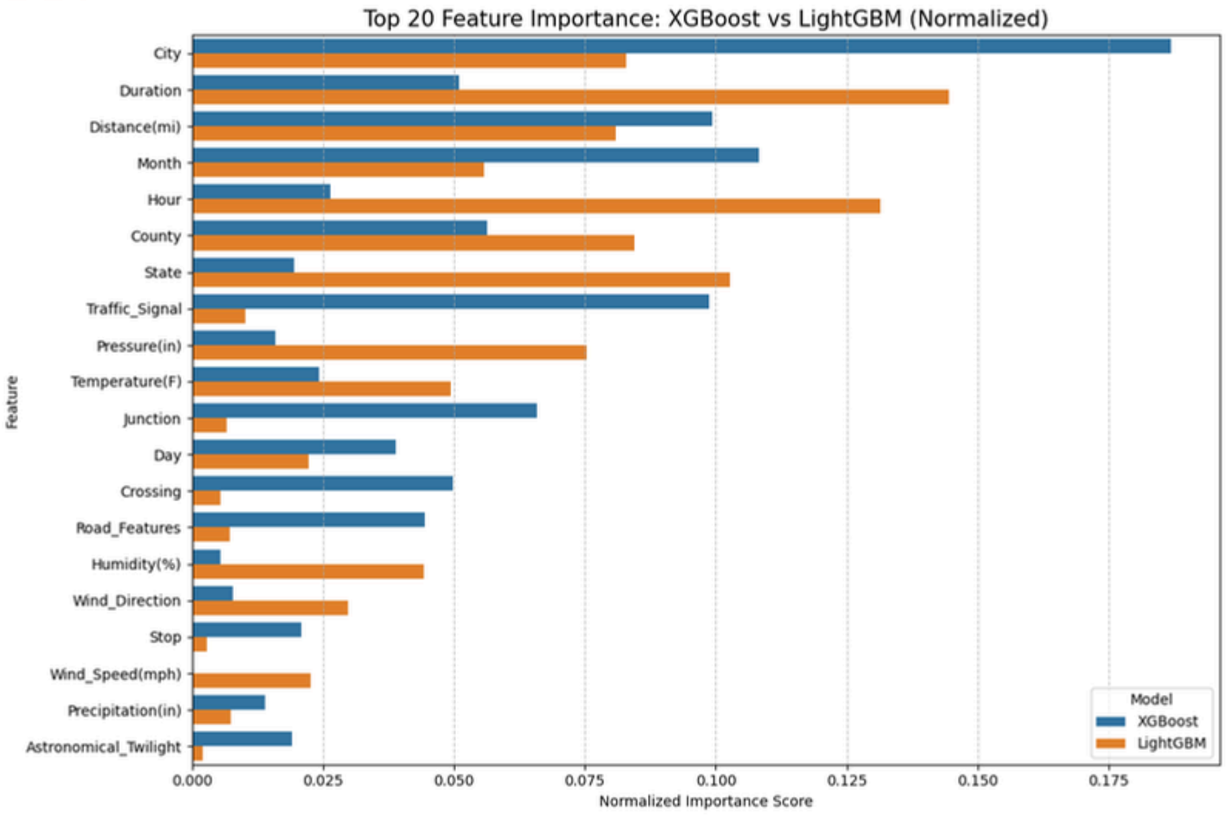

Model
Random Forest

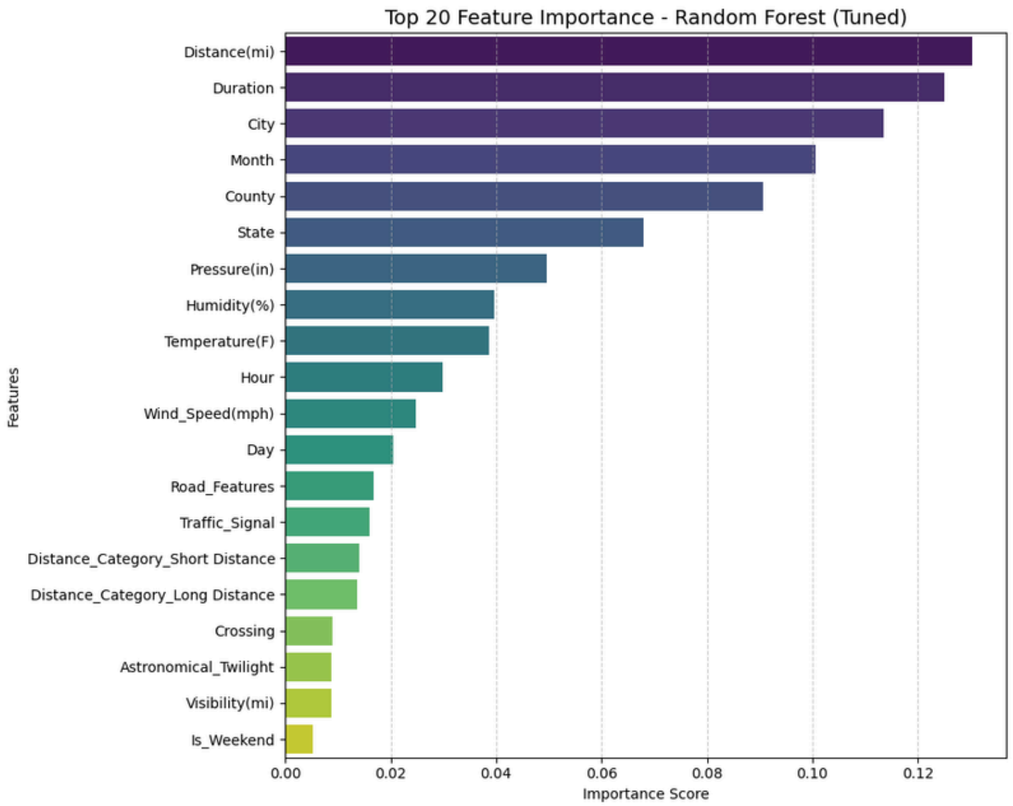

Balancing Target

- Melakukan undersampling menggunakan RandomUnderSampler pada kelas severity 2
- Melakukan Oversampling menggunakan SMOTE pada kelas severity 1, 3, dan 4

Distribusi Severity Sebelum Balancing

	Severity
1	19860
2	653886
3	129746
4	21747

Distribusi Severity Setelah Balancing

	Severity
1	180000
2	233530
3	185000
4	180000

Analisis Model

Model
Logistic Regression

	precision	recall	f1-score
1	0.10	0.71	0.18
2	0.89	0.57	0.70
3	0.28	0.29	0.28
4	0.05	0.30	0.09

Akurasi: 52%

Model
Random Forest

	precision	recall	f1-score
1	0.27	0.86	0.41
2	0.96	0.67	0.79
3	0.39	0.72	0.51
4	0.21	0.60	0.31

Akurasi: 68%

Kesimpulan & Insight

- Model berbasis tree (Random Forest, Ensemble XGBoost dan LightGBM) memberikan performa terbaik dibanding model linear dalam menangani data kompleks non-linear
- XGBoost mencapai accuracy tertinggi (86%), namun memiliki nilai recall yang sangat kecil pada Severity 4 dibandingkan Random Forest
- Handling imbalance berpengaruh signifikan, namun resampling tidak selalu meningkatkan performa karena dapat menambahkan noise pada data
- Handling imbalance dengan Class_Weight pada model lebih efektif dibandingkan resampling penuh
- Scaling dan log transformation tidak memberikan peningkatan signifikan pada model berbasis tree
- Feature engineering dan feature selection dapat membantu model menangkap pola dengan lebih baik
- Model mampu mendeteksi kecelakaan dengan tingkat keparahan tinggi (severity 3 & 4) dengan lebih baik setelah dilakukan hyperparameter tuning, dibuktikan dengan meningkatnya F1-Score (khususnya recall)
- Faktor seperti jarak, durasi kecelakaan, kota, dan bulan memiliki pengaruh yang cukup besar terhadap tingkat keparahan

Referensi

- Jannah, R., Marpaung, F., Ruhiyat, Y., & Saefullah, A. (2024). Analisis Pola Distribusi Awan Sebelum dan Selama Pelaksanaan Teknologi Modifikasi Cuaca pada Periode CENS (Cross-Equatorial Northerly Surge) Tahun 2022 di Provinsi Banten. Jurnal Sains & Teknologi Modifikasi Cuaca, 25(1), 13–22.
- Nuraini, N., & Fitri, N. I. Analisis Sifat Hujan dan Rata-Rata Temperatur Udara Bulanan Stasiun Meteorologi Maritim Tanjung Mas Periode 2015-2019 Terhadap Data Normal Selama 30 Tahun. Program Studi Meteorologi, Sekolah Tinggi Meteorologi Klimatologi dan Geofisika.

Thank You So Much!